



M1 - DATA ENGINEERING & IA

Projet Machine Learning

Prediction de la qualite du vin
Dataset Wine Quality (UCI / Kaggle)

Auteurs

Adam BELOUCIF

Emilien MORICE

EFREI Paris Pantheon-Assas Universite

Avril 2026

Sommaire

1. Probleme
2. Donnees
3. Analyse exploratoire (EDA)
4. Preparation
5. Modelisation
6. Evaluation
7. Analyse
8. Conclusion

1. Probleme

Contexte

La qualite d'un vin est habituellement evaluee par des oenologues experts, ce qui est couteux, lent et subjectif. Les proprietes physico-chimiques d'un vin (acidite, sucre residuel, alcool, sulfates, etc.) sont mesurables a bas cout par des instruments de laboratoire. La question posee est donc : peut-on predire la qualite percue d'un vin a partir de ses seules caracteristiques physico-chimiques ?

Objectif metier

Fournir a un producteur viticole un outil de scoring automatique qui :

- distingue les vins de haute qualite (note ≥ 7 , gamme premium) des vins ordinaires (note < 7),
- identifie les variables physico-chimiques qui influencent le plus la qualite, pour piloter le processus de vinification,
- segmente la production en profils pour cibler differentes gammes de marche.

Pertinence : reduction du cout d'expertise, standardisation de l'evaluation, optimisation continue des process de production.

2. Données

Source

Dataset public Wine Quality du UCI Machine Learning Repository, disponible également sur Kaggle sous l'identifiant `uciml/red-wine-quality-cortez-et-al-2009`. Deux fichiers : vins rouges et vins blancs portugais (variété Vinho Verde).

Reference : Cortez, Cerdeira, Almeida, Matos, Reis, Modeling wine preferences by data mining from physicochemical properties, Decision Support Systems 47(4), 2009.

Description

- 5320 enregistrements après déduplication (rouges + blancs fusionnés).
- 11 variables explicatives numériques : acidité fixe, acidité volatile, acide citrique, sucre résiduel, chlorures, SO₂ libre, SO₂ total, densité, pH, sulfates, alcool.
- 1 variable cible quality (score entier de 0 à 10).
- 1 variable ajoutée type (red / white) pour encoder l'origine.
- Cible binaire dérivée : `quality_binary = (quality >= 7)`, taux positifs = 19.0%.

Limitations

- Dataset fortement déséquilibré : la majorité des vins ont une note médiane (5-6).
- Vins d'une seule région (Vinho Verde), faible généralisation géographique.
- Notes subjectives moyennes de 3 juges.
- Pas de variables contextuelles (millésime, température de fermentation, cépage précis).

3. Analyse exploratoire (EDA)

Points clés

- Aucune valeur manquante détectée, quelques doublons exacts (~1000) supprimés.
- Classes fortement déséquilibrées : environ 20% seulement de vins qualifiés de bons (note ≥ 7).
- L'alcool est la variable la plus corrélée positivement avec la qualité ($\sim +0.44$).
- Les sulfates et le type (rouge/blanc) complètent le signal principal.
- L'acidité volatile est corrélée négativement (-0.27) : trop d'acétate dégrade le goût.
- Densité et sucre résiduel sont redondants entre eux.




Figure 1 - Distribution des scores de qualité et binarisation de la cible.




Figure 2 - Matrice de corrélation des variables physico-chimiques.

Distribution des features selon la classe (rouge=ordinaire, vert=bon)




Figure 3 - Distribution des features selon la classe cible (rouge = ordinaire, vert = bon).

Analyse non supervisee : PCA + KMeans

Une analyse en composantes principales (PCA) 2D et un clustering KMeans ont ete realises sur les variables standardisees, sans utiliser la cible. Les deux premieres composantes capturent environ 50% de la variance totale.




Figure 4 - Projection PCA des vins, coloree par type puis par classe de qualite.




Figure 5 - Methode du coude : $k = 3$ clusters retenu.




Figure 6 - Segmentation KMeans ($k = 3$) projetee sur le plan PCA.

KMeans retrouve spontanement trois profils qui correspondent grossierement a des vins blancs doux, des vins blancs secs de qualite et des vins rouges. La proportion de bons vins varie entre clusters, ce qui confirme qu'une partie du signal qualite est deja presente sans supervision.

4. Preparation

Nettoyage

- Fusion des deux fichiers red + white avec une variable type ajoutée.
- Suppression des doublons exacts (potentielles erreurs de saisie).
- Vérification des valeurs manquantes : aucune.
- Outliers conservés car ce sont de vrais vins, le scaling les absorbe.

Ingenierie de features

- Binarisation de la cible : `quality_binary = (quality >= 7)`.
- Encodage one-hot du type de vin (red / white) avec drop de la première modalité.
- Standardisation des variables numériques via `StandardScaler`.
- Encapsulation dans un `ColumnTransformer` + Pipeline `sklearn` : les transformations sont apprises uniquement sur le train, puis appliquées au test, ce qui évite toute fuite de données.

Split train/test

Decoupage stratifié 80% / 20% (`random_state = 42`). La stratification garantit que la proportion de la classe minoritaire (bons vins) est préservée entre train et test.

5. Modelisation

Modeles implementes

- Logistic Regression - baseline lineaire interpretable.
- Random Forest - methode d'ensemble par bagging, robuste aux non-linearites.
- Gradient Boosting (sklearn) - methode d'ensemble par boosting.
- XGBoost - boosting de gradient optimise, reference sur donnees tabulaires.

Justification

La regression logistique sert de point de reference. Random Forest et Boosting sont explicitement requis par le cahier des charges. XGBoost apporte une optimisation supplementaire, souvent championne sur ce type de dataset.

Tous les modeles sont construits via un meme Pipeline (preprocessing + classifieur) pour garantir une comparaison equitable. Les classes desequilibrees sont compensees par `class_weight=balanced` (LogReg, Random Forest) et `scale_pos_weight` (XGBoost).

6. Evaluation

Metriques

- Accuracy - informative mais trompeuse sur classes desequilibrees.
- Precision - parmi les vins predits bons, quel pourcentage l'est vraiment.
- Recall - parmi les vrais bons vins, combien sont retrouves.
- F1-score - moyenne harmonique precision/recall, metrique principale choisie.
- ROC-AUC - qualite globale du classement probabiliste.

Tableau comparatif

Modele	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.731	0.395	0.782	0.525	0.817
Random Forest	0.846	0.698	0.332	0.450	0.878
Gradient Boosting	0.844	0.648	0.391	0.488	0.852
XGBoost	0.834	0.557	0.609	0.582	0.858

Ligne en surbrillance - meilleur modele selon le F1 (XGBoost).




Figure 7 - Comparaison visuelle des metriques sur le jeu de test.




Figure 8 - Matrices de confusion des quatre modeles.




Figure 9 - Courbes ROC et AUC comparees.

7. Analyse

Interpretation des resultats

Le meilleur modele sur le F1-score est XGBoost (F1 = 0.582, ROC-AUC = 0.858). Les methodes d'ensemble surpassent systematiquement la regression logistique, ce qui indique que la frontiere entre bons vins et vins ordinaires n'est pas lineaire et exploite des interactions entre variables physico-chimiques.

Les matrices de confusion montrent une precision elevee : les modeles classent rarement un vin ordinaire comme premium, ce qui est le comportement attendu en viticulture (eviter de sur-valoriser un produit qui decevrait a la degustation).




Figure 10 - Importance des variables selon le meilleur modele d'ensemble.

Lecture metier

- L'alcool reste la variable la plus discriminante : les bons vins ont en moyenne un taux plus eleve (signe de maturite des raisins).
- Les sulfates et l'acidite volatile sont les deux autres leviers majeurs.
- Le type de vin (rouge/blanc) ameliore legerement les performances sans etre suffisant a lui seul.
- Densite et sucre residuel apportent un signal redondant mais utile pour separer les profils.

8. Conclusion

Recommandations

- Deployer le modele boosting retenu comme outil de pre-screening dans le laboratoire qualite : reduction massive du temps d'expertise humaine.
- Piloter la vinification en maximisant les variables a fort impact positif : viser un alcool superieur a 11%, des sulfates eleves, et limiter l'acidite volatile sous 0.4 g/L.
- Segmenter la gamme commerciale selon les clusters KMeans : chaque profil correspond a un positionnement marche distinct.
- Retenir le F1-score comme KPI de suivi plutot que l'accuracy, compte tenu du desequilibre de classes.

Limitations et travaux futurs

- Dataset geographiquement restreint (Vinho Verde) : collecter des vins d'autres regions pour generaliser le modele.
- Cible subjective (moyenne de 3 juges) : un protocole d'annotation plus large ameliorerait le signal.
- Tester des modeles supplementaires : CatBoost, LightGBM, reseaux tabulaires type TabNet.
- Tuning d'hyperparametres systematique via GridSearchCV ou Optuna.
- Passer en regression ordinale sur le score 0-10 plutot que la binarisation.
- Ajouter des features exogenes (millesime, temperature de fermentation, cepage) pour capturer plus de variance.

Projet realise par Adam BELOUCIF et Emilien MORICE dans le cadre du Master 1 Data Engineering & IA, EFREI Paris Pantheon-Assas Universite, annee universitaire 2025-2026.